

Biometría, ejercicios prácticos

Marcos Esteve Casademunt

Junio 2020

Contents

1	PCA	2
2	LDA	3
3	Implementación de la triplet loss	3

1 PCA

Para el desarrollo de este ejercicio se han realizado dos aproximaciones. Una primera utilizando el toolkit scikit learn y una segunda realizando una implementación desde cero. Los detalles de implementación se pueden ver en el fichero adjunto

En ambas aproximaciones se obtienen los mejores resultados de clasificación por vecino más cercano cuando se realiza una reducción de la dimensionalidad de los datos a **91** dimensiones. Consiguiendo de esta forma una precisión **90.5%**. A continuación se muestran la grafica con la precisión obtenida al variar la dimensionalidad obtenida por PCA.




Figure 1: Evolución del *accuracy* obtenido por vecino más cercano al variar la dimensionalidad con PCA

Por otra parte, también se puede mostrar alguna EigenFace como la detallada en la figura 2

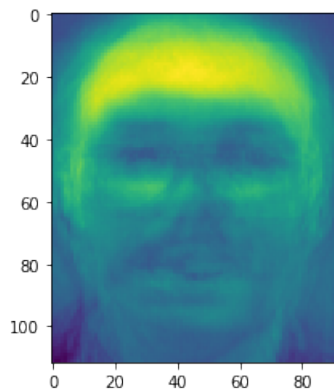


Figure 2: Ejemplo de EigenFaces

2 LDA

Para el desarrollo de este ejercicio primeramente se ha reducido la matriz de datos a **200 dimensiones** para posteriormente aplicar la técnica de LDA y reducir la dimensionalidad hasta como máximo 39 dimensiones. A continuación se muestra la evolución de la precisión al modificar el número de dimensiones con LDA.

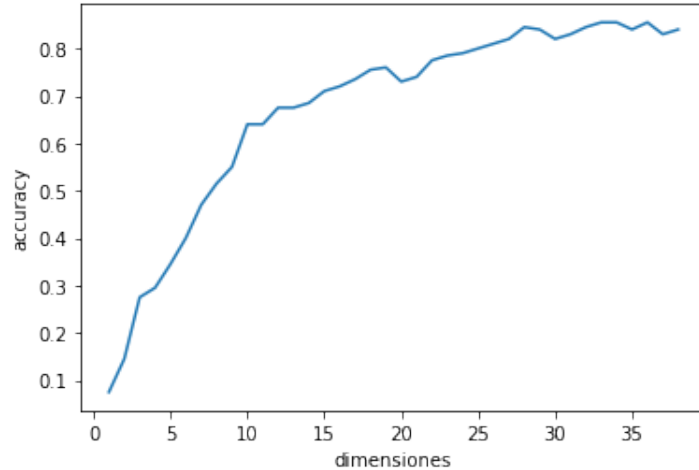


Figure 3: Evolución del *accuracy* obtenido por vecino más cercano al variar la dimensionalidad con LDA

Tal y como se puede observar la mejor precisión obtenida se consigue con **32 dimensiones** siendo esta de un **85.5%**. Cabe destacar que es significativamente inferior a la obtenida con PCA.

3 Implementación de la triplet loss

El objetivo de este ejercicio consiste en implementar redes siamesas utilizando la función de pérdida triplet loss para aprender una representación de los datos que permita:

- Imágenes de la misma persona deberán de tener una representación cercana entre si
- Imágenes de distintas personas deberán de tener representaciones lejanas entre si

Por ejemplo, tal y como se puede observar en la figura 4, se observa que las imágenes Anchor y Positive pertenecen a la misma persona y por tanto, deberán de tener una representación más cercana que las fotografías Anchor y Negative cuyas imágenes pertenecen a distintas personas

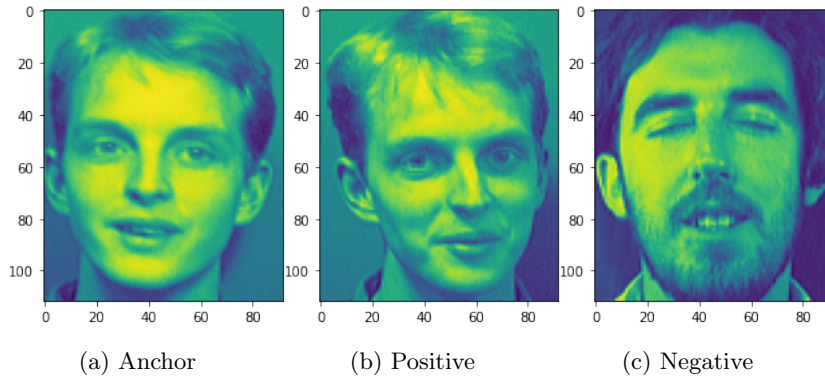


Figure 4: Muestras extraídas del dataset ORL

Para ello se ha realizado una implementación en keras de redes siamesas y se ha introducido la función triplet loss adaptada de <https://github.com/davidsandberg/facenet/blob/master/src/facenet.py>.

Además ha sido necesario crear un generador que devuelva batches aleatorios formados por imágenes anchor, positive y negative. Los detalles de la implementación se pueden observar en https://colab.research.google.com/drive/1eVKpzS23NeG_a18-54TMxk8VtkfRQimU.

A la hora de realizar la experimentación se ha utilizado $\alpha = 1$ y se ha evaluado como afecta el tamaño de la representación obtenida por la red siamesa a la precisión en etapa de clasificación con el algoritmo de K vecinos más cercanos.

	Tamaño representación			
k	25	50	100	200
1	81.5	82.5	85.5	86.5
2	81.0	75.0	75.5	78.5
3	77.1	76.0	75.0	80.5

Table 1: Evolución de la precisión al variar el tamaño de la representación generada por la red siamesa y el valor de K en el algoritmo K-vecinos

Tal y como podemos observar en la tabla se observa una tendencia ascendente en la precisión al aumentar la dimensionalidad del vector que representa a cada imagen. Se obtienen los mejores resultados cuando la dimensionalidad del vector es de **200** y el número de vecinos (k) es 1. Como se puede observar los resultados no consiguen mejorar a los resultados obtenidos por PCA.

A modo de trabajo futuro o posibles mejores se podría plantear que el sistema, en lugar de coger batches aleatorios, cogiera aquellas muestras que son más inciertas para el sistema y de esta forma, realizar un mejor entrenamiento de la red siamesa. Además, se podría considerar el entrenamiento de un modelo siamés con un mayor conjunto de datos, permitiendo de esta forma captar una mayor variabilidad y probablemente un aumento en la precisión.